

DETECȚIA TEXTULUI GENERAT DE AI PRIN FINE-TUNING ROBERTA

Candidat: Flavius-Alin FARCA

Coordonator științific: ș.l.dr.ing. Norbert GAL-NĂDĂȘAN

Sesiunea: Iunie 2026

REZUMAT

Odată cu proliferarea modelelor lingvistice de mari dimensiuni, detectarea automată a textelor generate de inteligența artificială devine o sarcină din ce în ce mai importantă. În cadrul acestei cercetări, se propune și se evaluează o metodă de detecție bazată pe fine-tuningul modelului RoBERTa antrenat pe dataset-ul HC3 și extins cu texte generate de cinci modele de inteligență artificială diferite. Modelul final RoBERTa v2 a obținut o acuratețe de 99,62% în scenariul in-domain. În cazul testării cross-model pe NVIDIA Nemotron (un model complet nevăzut în timpul antrenării), detectorul a obținut o acuratețe de 88,49%. Pe setul RAID, acuratețea medie pe cele 10 modele cross-model evaluate (excluzând ChatGPT, model in-domain) a fost de 88,09%, variind între 61,30% (pentru modelul Mistral de bază) și 99,00% (pentru Llama-chat). Validarea externă a confirmat capacitatea de generalizare a detectorului în scenariile testate.

ABSTRACT

Along with the rise of large-scale language models, the automatic detection of artificial intelligence generated text is becoming an increasingly important task. In this research, we propose and evaluate a detection method based on an enhanced version of the RoBERTa model trained on the HC3 dataset and extended with text generated by five different artificial intelligence models. The final RoBERTa v2 model achieved an accuracy of 99.62% in the in-domain scenario. When evaluated in a cross-model scenario on NVIDIA Nemotron (a model completely unseen during training), the detector achieved an accuracy of 88.49%. On the RAID Benchmark, the average accuracy across the 10 evaluated cross-model AI models (excluding ChatGPT, the in-domain model) was 88.09%, ranging from 61.30% (for the base Mistral model) to 99.00% (for Llama-chat). External validation confirmed the detector's generalization capability in the tested scenarios.

CUPRINS

Cuprins

1. INTRODUCERE ȘI MOTIVAREA PROBLEMEI.....	6
1.1. OBIECTIVELE LUCRĂRII	6
1.2. STRUCTURA LUCRĂRII.....	6
2. STUDIU BIBLIOGRAFIC: ANALIZA STADIULUI ACTUAL ÎN DOMENIUL PROBLEMEI.....	8
2.1. CONTEXTUL PROBLEMEI	8
2.2. METODE DE DETECȚIE A TEXTULUI GENERAT DE AI	8
2.2.1. METODE STATISTICE ȘI BAZATE PE PERPLEXITATE	9
2.2.2. METODE BAZATE PE MODELE TRANSFORMER	9
2.3. DATASET-URI DE REFERINȚĂ	10
2.4. INSTRUMENTE COMERCIALE DE DETECȚIE	10
2.5. LIMITĂRI ALE METODELOR EXISTENTE ȘI MOTIVAREA ABORDĂRII PROPUSE.....	11
3. FUNDAMENTARE TEORETICĂ.....	12
3.1. ARHITECTURA TRANSFORMER	12
3.2. BERT — BIDIRECTIONAL ENCODER REPRESENTATIONS FROM TRANSFORMERS	12
3.3. ROBERTA — ROBUSTLY OPTIMIZED BERT PRETRAINING APPROACH	12
3.4. TF-IDF ȘI LOGISTIC REGRESSION	13
3.5. METRICI DE EVALUARE	14
4. SOLUȚIA PROPUȘĂ ȘI METODOLOGIA DE PROIECTARE/DEZVOLTARE ..	15
4.1. DESCRIEREA DATASET-ULUI HC3	15
4.2. PREPROCESAREA ȘI ECHILIBRAREA DATELOR	15
4.3. EXTINDEREA DATASET-ULUI CU TEXTE MULTI-MODEL.....	16
4.4. CURĂȚAREA ȘI VERIFICAREA DATELOR	17
4.5. CONSTRUIREA DATASET-ULUI FINAL ȘI ÎMPĂRȚIREA ÎN SUBSETURI	17
5. IMPLEMENTARE.....	19
5.1. MEDIUL DE DEZVOLTARE ȘI TEHNOLOGII UTILIZATE	19

5.2. IMPLEMENTAREA MODELULUI BASELINE — TF-IDF + LOGISTIC REGRESSION	19
5.3. IMPLEMENTAREA FINE-TUNING ROBERTA.....	20
5.4. PIPELINE-UL DE GENERARE A TEXTELOR MULTI-MODEL.....	21
5.5. SALVAREA ȘI UTILIZAREA MODELULUI.....	21
6. REZULTATE EXPERIMENTALE	23
6.1. REZULTATE BASELINE (TF-IDF + LOGISTIC REGRESSION).....	23
6.2. REZULTATE ROBERTA V1 (ANTRENAT EXCLUSIV PE CHATGPT).....	24
6.3. REZULTATE ROBERTA V2 (ANTRENAT PE DATASET MULTI-MODEL).....	25
6.4. VALIDARE EXTERNĂ PE RAID BENCHMARK.....	27
6.5. COMPARAȚIE FINALĂ	30
7. CONCLUZII, CONTRIBUȚII ȘI DIRECȚII DE CONTINUARE A DEZVOLTĂRII	32
7.1. CONCLUZII	32
7.2. CONTRIBUȚIILE ORIGINALE ALE LUCRĂRII	32
7.3. LIMITĂRI	32
7.4. DIRECȚII VIITOARE DE CERCETARE.....	33
8. BIBLIOGRAFIE	34

1. INTRODUCERE ȘI MOTIVAREA PROBLEMEI

Fluența tot mai mare și utilizarea pe scară largă a modelelor lingvistice de mari dimensiuni (LLM) [7] au determinat o creștere semnificativă a prezenței textului generat de inteligența artificială în diverse domenii. Modele precum ChatGPT (OpenAI), Gemini (Google) și Llama (Meta) pot genera mesaje aproape identice cu cele produse de oameni în ceea ce privește coerența, fluența și conținutul informațional. Domeniile educației, mass-media, securității informaționale și integrității academice sunt grav afectate de acest fenomen [8].

Instituțiile de învățământ caută soluții tehnologice pentru detectarea automată a textelor generate de AI, din cauza utilizării necorespunzătoare a modelelor de inteligență artificială pentru producerea de lucrări științifice [8]. În mod similar, creșterea numărului de știri false și de conținut dezinformativ generate mecanic în sectorul mass-media a atras atenția asupra necesității unor metode fiabile de verificare a autenticității textelor [7].

Abordarea de identificare automată a textelor generate de inteligență artificială propusă în acest studiu se bazează pe fine-tuning-ul modelului RoBERTa pre-antrenat [1]. Pentru evaluarea sistemului sunt utilizate atât scenariul „in-domain” – texte generate de același model de inteligență artificială folosit în timpul antrenării – cât și scenariul „cross-model” – texte generate de modele de inteligență artificială complet diferite de cele folosite în timpul antrenării. Această evaluare duală abordează o întrebare importantă de cercetare: detectoarele antrenate pe texte provenite de la un anumit model de inteligență artificială își mențin eficacitatea atunci când se confruntă cu modele de nouă generație?

1.1. OBIECTIVELE LUCRĂRII

Obiectivele principale ale prezentei lucrări sunt:

- (1) Implementarea unui sistem de detecție a textului AI bazat pe fine-tuning RoBERTa, antrenat pe dataset-ul HC3 [2];
- (2) Evaluarea comparativă a două abordări, un model baseline TF-IDF + Logistic Regression și modelul RoBERTa, în scenarii in-domain și cross-model;
- (3) Extinderea dataset-ului de antrenare cu texte generate de modele AI diverse și demonstrarea impactului acestei diversificări asupra capacității de generalizare;
- (4) Validarea externă a sistemului pe RAID Benchmark [3], un dataset de referință din literatura de specialitate.

1.2. STRUCTURA LUCRĂRII

Lucrarea este organizată după cum urmează. Capitolul 2 prezintă un studiu bibliografic al metodelor existente de detecție a textului AI. Capitolul 3 oferă fundamentarea teoretică a arhitecturilor utilizate. Capitolul 4 descrie soluția propusă și metodologia de construire a dataset-ului. Capitolul 5 detaliază implementarea sistemului. Capitolul 6

prezintă rezultatele experimentale obținute. Capitolul 7 conține concluziile și direcțiile viitoare de cercetare.

2. STUDIU BIBLIOGRAFIC: ANALIZA STADIULUI ACTUAL ÎN DOMENIUL PROBLEMEI

În ultimii ani, domeniul identificării automate a textelor generate de inteligență artificială a înregistrat progrese rapide, odată cu dezvoltarea accelerată a modelelor lingvistice de mari dimensiuni. În acest capitol se analizează stadiul actual al cercetării, abordând instrumentele comerciale disponibile, seturile de date de referință, tehnicile de detectare și dezavantajele cunoscute ale metodelor existente.

2.1. CONTEXTUL PROBLEMEI

Lansarea ChatGPT în noiembrie 2022 a marcat un punct de cotitură semnificativ în utilizarea pe scară largă a modelelor generative de text. Integrarea rapidă a acestora în sectoarele de afaceri, academic și jurnalistic a ridicat întrebări importante cu privire la autenticitatea textelor.

Această presiune i-a determinat pe cercetători să caute soluții tehnologice riguroase pentru protejarea publicațiilor științifice. De exemplu, Desaire et al. (2023) [16] au obținut o acuratețe de peste 99% la nivel de document pentru articole științifice academice (Perspectives din Science), folosind un set restrâns de caracteristici lingvistice. Acest rezultat demonstrează fezabilitatea detecției în contexte bine definite, dar performanța scade semnificativ în afara domeniului respectiv, așa cum arată și studiile anterioare.

Instituții academice de renume, precum University of Oxford, au stabilit norme clare privind utilizarea IA, considerând utilizarea neautorizată a acesteia în lucrările academice drept abatere disciplinară echivalentă cu plagiatul [20]. În acest context, detectarea automată a textului generat de IA a devenit un subiect de actualitate, cu consecințe imediate asupra menținerii integrității academice și a evaluării corecte a studenților.

Din punct de vedere tehnic, problema este extrem de complicată, deoarece modelele generative contemporane produc texte coerente, fluide și greu de distins de scrierea umană. În plus, un studiu realizat de cercetătorii de la Stanford [8] a constatat că detectoarele de conținut generat de IA prezintă un bias semnificativ împotriva vorbitorilor de limbă engleză care nu sunt nativi. În cazul eseurilor TOEFL examinate, autorii au raportat o rată medie de fals pozitive de 61,22%, iar 19,78% dintre eseuri au fost clasificate în unanimitate de toate detectoarele evaluate ca fiind generate de IA. Aceste constatări ridică întrebări etice semnificative cu privire la aplicarea acestor instrumente în contextul evaluării și al procesului de învățământ.

2.2. METODE DE DETECȚIE A TEXTULUI GENERAT DE AI

Metodele de detecție a textului AI pot fi clasificate în două categorii principale: metode statistice bazate pe caracteristici ale distribuției de probabilitate a limbajului și metode bazate pe modele de clasificare antrenate supervizat.

2.2.1. METODE STATISTICE ȘI BAZATE PE PERPLEXITATE

Prima categorie de tehnici se bazează pe diferențele statistice dintre textul generat de IA și cel creat de oameni. Spre deosebire de textul uman, care se caracterizează printr-o mai mare diversitate stilistică și imprevizibilitate, textul generat de modelele lingvistice de mari dimensiuni este, de obicei, mai previzibil și anume, prezintă mai puține neconcordanțe în raport cu modelul generativ.

Una dintre cele mai populare tehnici de tip „zero-shot” pentru identificarea textelor generate de IA este DetectGPT, propusă de Mitchell et al. (2023) [7]. Abordarea se bazează pe constatarea că textele generate de IA se încadrează, de obicei, în zonele cu probabilitate ridicată ale modelului generativ; în special, modificările minore aduse unui text generat de IA tind să îi reducă probabilitatea logaritmică, în timp ce modificările aduse textelor scrise de oameni au efectul invers. DetectGPT are nevoie doar de acces la modelul generativ pentru a calcula probabilitatea; antrenarea supravegheată nu este necesară. Principalul dezavantaj al acestei metode este că nu este aplicabilă în situații reale, deoarece necesită cunoașterea modelului generativ sursă.

Tehnica de referință tradițională pentru clasificarea textelor este reprezentată de metodele bazate pe TF-IDF (Term Frequency-Inverse Document Frequency).

2.2.2. METODE BAZATE PE MODELE TRANSFORMER

În cea de-a doua categorie de abordări, mai moderne și mai performante, se utilizează modele bazate pe arhitectura Transformer, pre-antrenate și optimizate pentru sarcini de clasificare binară. Această metodă distinge conținutul generat de IA de stilurile de scriere umane, folosind reprezentările semantice bogate înregistrate în timpul pre-antrenării.

Solaiman et al. (2019) [10] de la OpenAI au dezvoltat un detector bazat pe RoBERTa, care a fost perfecționat pe text generat de GPT-2 și a atins o acuratețe de aproximativ 95% pe datele GPT-2. Autorii au constatat că fine-tuning-ul generatorului pentru un anumit domeniu (de exemplu, pe recenzii de pe Amazon) reduce acuratețea la 76%, în ciuda generalizării bune a detectorului în cazul diverselor tehnici de eșantionare și dimensiuni ale modelului în cadrul aceleiași arhitecturi. Acest lucru scoate la iveală o vulnerabilitate în fața adversarilor care modifică modelul. Această limitare subliniază necesitatea diversificării surselor de antrenare pentru a promova generalizarea cross-model și evidențiază dificultatea de a menține o performanță ridicată în condiții de ajustare adaptivă.

Wang et al. (2023) [9] au creat și comparat modele BERT și RoBERTa fine-tuned pentru detectarea știrilor generate de ChatGPT, obținând o acuratețe de 98% în scenariul

„in-domain”. Cercetarea lor oferă un punct de referință clar pentru abordarea utilizată în studiul de față și confirmă superioritatea modelelor bazate pe transformer față de alte arhitecturi neuronale (cum ar fi CNN sau LSTM).

Dependența tuturor tehnicilor bazate pe fine-tuning de distribuția datelor de antrenare reprezintă un dezavantaj major. Atunci când sunt testate pe texte provenite de la diverse modele, modelele care au fost antrenate exclusiv pe textul provenit de la un singur model de IA (cum ar fi ChatGPT) prezintă o scădere bruscă a performanței - o caracteristică care a fost descrisă metodic în literatura de specialitate și verificată experimental în lucrarea de față.

2.3. DATASET-URI DE REFERINȚĂ

Progresul in-domain a fost facilitat de crearea unor dataset-uri publice de referință, care permit compararea obiectivă a metodelor de detecție.

HC3 (Human ChatGPT Comparison Corpus), propus de Guo et al. (2023) [2], este unul dintre primele și cele mai utilizate dataset-uri pentru detecția textului ChatGPT. Conține 24.322 de perechi întrebare-răspuns, cu răspunsuri atât de la utilizatori umani (din Reddit, Wikipedia, publicații medicale, finanțe), cât și de la ChatGPT, acoperind domenii diverse. HC3 este utilizat ca dataset principal de antrenare în prezenta lucrare.

Cel mai complet punct de referință pentru evaluarea robustă a detectoarelor de text bazate pe IA este RAID (Robust AI Detection), dezvoltat de Dugan et al. (2024) [3] de la Universitatea din Washington și disponibil pe HuggingFace [12]. Acesta include peste 5,6 milioane de texte generate de 11 modele distincte de IA (precum GPT-2, GPT-3, GPT-4, ChatGPT, Cohere, Mistral și Llama) în 8 domenii diferite, cu 11 metode diferite de atac adversarial (inclusiv parafrizarea, substituirea sinonimelor, inserarea de caractere speciale etc.). În lucrarea de față, RAID este utilizat pentru validarea externă.

TuringBench, dezvoltat de Uchendu et al. (2021) [13], permite evaluarea sistematică cross-model și include texte produse de 19 modele AI diferite. Dataset-ul a demonstrat că distanța arhitecturală dintre modelul de antrenare și modelul de testare reduce considerabil performanța detectorului.

2.4. INSTRUMENTE COMERCIALE DE DETECȚIE

Ca urmare a cererii tot mai mari, au apărut numeroase soluții comerciale de identificare a textelor generate de IA, printre care GPTZero [14] și Turnitin [15]. Deși aceste instrumente promit performanțe ridicate, evaluările independente relevă limitări semnificative. De exemplu, Schmalz și Tack (2025) [21] au evaluat funcția AI Vocabulary a GPTZero, o caracteristică ce evidențiază termeni considerați frecvenți în textele generate de modele lingvistice, pe un set de eseuri studentești și generate de ChatGPT și Claude. Rezultatele au arătat o acuratețe de doar 75,5% pentru textele ChatGPT, iar pentru cele generate de Claude performanța a scăzut aproape la nivel aleatoriu, demonstrând o

generalizare cross-model extrem de slabă. Mai mult, toate clasificatoarele bazate pe vocabularul GPTZero au fost semnificativ depășite de un simplu clasificator Bag-of-Words antrenat pe întregul vocabular al setului de date (acuratețe de 96,4%).

Investigații independente au arătat că un dezavantaj tipic al instrumentelor comerciale este susceptibilitatea lor la atacuri de parafrază; rescrierea textului generat de IA cu alte instrumente (cum ar fi Quillbot) poate reduce drastic ratele de detectare. În plus, fiecare dintre aceste instrumente demonstrează restricțiile stabilite în ceea ce privește vorbitorii non-nativi [8].

2.5. LIMITĂRI ALE METODELOR EXISTENTE ȘI MOTIVAREA ABORDĂRII PROPUSE

În analiza literaturii de specialitate sunt evidențiate trei deficiențe fundamentale ale tehnicilor actuale de detectare.

Absența generalizării cross-model reprezintă primul și cel mai important neajuns. Atunci când sunt testate pe texte provenite de la diverse modele de IA, metodele antrenate pe texte dintr-un anumit model prezintă o scădere semnificativă a performanței. Metoda de antrenare pe mai multe surse propusă în acest studiu este motivată în primul rând de această problemă, care a fost descrisă în repetate rânduri în literatura de specialitate.

Conform lui Liang et al. (2023) [8], al doilea dezavantaj este bias-ul vorbitorilor de limbă engleză care nu sunt nativi. Ratele ridicate de fals pozitive rezultă din paralelele dintre tiparele de text generate de IA și stilurile de scriere ale vorbitorilor care nu sunt nativi, caracterizate prin propoziții scurte, structuri repetitive și terminologie simplificată. Utilizarea detectoarelor în mediile educaționale este direct afectată de această dilemă etică.

Vulnerabilitatea la atacuri ostile reprezintă a treia limitare. Cercetările recente au demonstrat că modificările simple aduse textului generat de IA, precum parafrizarea, introducerea de erori intenționate și înlocuirea cu sinonime, reduc semnificativ acuratețea detectorului. Robustețea poate fi evaluată, deoarece RAID Benchmark [3] include în mod specific acest tip de atacuri în cadrul evaluării sale.

Strategia prezentată în această lucrare este motivată de următoarele constrângeri: suplimentarea setului de date cu texte din diverse surse de antrenare pentru a îmbunătăți generalizarea cross-model; efectuarea unei evaluări metodice pe RAID Benchmark pentru a măsura performanța practică; și dezvăluirea deschisă a constrângerilor rămase.

3. FUNDAMENTARE TEORETICĂ

3.1. ARHITECTURA TRANSFORMER

Mecanismul de atenție al arhitecturii Transformer, prezentat pentru prima dată de Vaswani et al. în 2017 [4], a revoluționat domeniul procesării limbajului natural. Transformer procesează întreaga secvență în paralel, captând dependențele pe distanțe lungi prin intermediul mecanismului de auto-atenție, spre deosebire de arhitecturile recurente (RNN, LSTM), care procesează secvențele token cu token.

Pentru fiecare token din secvență, mecanismul de auto-atenție calculează o reprezentare ponderată a fiecărui alt token, permițând modelului să înțeleagă contextul general al textului. Deoarece stilul de scriere al modelelor generative apare la nivelul coerenței globale, mai degrabă decât doar prin cuvinte individuale, această proprietate este crucială pentru identificarea textului de către IA.

Din punct de vedere formal, mecanismul de auto-atenție utilizează trei matrice: de interogări (Q), de chei (K) și de valori (V), pentru a calcula o pondere pentru fiecare pereche de tokeni din secvență, conform relației:

$$Attention(Q, K, V) = softmax\left(Q \frac{K^T}{\sqrt{d_k}}\right)V \quad (1)$$

unde d_k reprezintă dimensiunea vectorilor de chei, iar împărțirea la $\sqrt{d_k}$ normalizează produsul scalar pentru a evita valori prea mari înainte de softmax.

3.2. BERT — BIDIRECTIONAL ENCODER REPRESENTATIONS FROM TRANSFORMERS

Modelarea limbajului mascat (MLM – Masked Language Modelling) și predicția propoziției următoare (NSP – Next Sentence Prediction) sunt cele două obiective de antrenare utilizate pentru pre-antrenarea modelului BERT (Devlin et al., 2018) [5] pe corpusuri de text de mari dimensiuni. Prin intermediul pre-antrenării, BERT captează reprezentări contextuale bogate ale textului, iar aceste reprezentări pot fi apoi perfecționate pentru o varietate de sarcini de clasificare, inclusiv identificarea textului prin intermediul IA. Formal, obiectivul Masked Language Model minimizează pierderea negativă a log-probabilității pentru tokenii mascați, conform relației:

$$\mathcal{L}_{MLM} = -\sum_{i \in \mathcal{M}} \log P(x_i | x_{\setminus \mathcal{M}}) \quad (2)$$

unde $\mathcal{M}$ reprezintă mulțimea pozițiilor mascate, x_i este tokenul original de la poziția i , iar $x_{\setminus \mathcal{M}}$ reprezintă secvența de intrare cu tokenii mascați eliminați.

3.3. ROBERTA — ROBUSTLY OPTIMIZED BERT PRETRAINING APPROACH

O versiune îmbunătățită a modelului BERT, denumită RoBERTa (Liu et al., 2019) [1], a fost creată prin modificarea procesului de pre-antrenare. Aceasta a inclus eliminarea obiectivului de predicție a propoziției următoare (NSP), antrenarea cu loturi mai mari și secvențe mai lungi, precum și utilizarea unui corpus mai extins (160 GB, față de cei 16 GB ai modelului BERT). Toate benchmark-urile comune din domeniul NLP au înregistrat creșteri notabile de performanță ca urmare a acestor modificări.

RoBERTa adaugă un cap de clasificare, un strat liniar cu o funcție de activare softmax, la reprezentarea $\langle s \rangle$ (echivalentul tokenului [CLS] din BERT) a secvenței pentru fine-tuning în sarcinile de clasificare binară. Modelul final generează o distribuție de probabilitate asupra claselor țintă folosind text tokenizat ca intrare. Clasele din acest studiu sunt specificate după cum urmează: text generat de IA (etichetă 1) și text uman (etichetă 0). Probabilitatea că un text aparține clasei c este calculată astfel:

$$P(y = c | \mathbf{h}) = \frac{e^{W_c \mathbf{h} + b_c}}{\sum_{j=1}^2 e^{W_j \mathbf{h} + b_j}} \quad (3)$$

unde $\mathbf{h}$ este reprezentarea vectorială a tokenului $\langle s \rangle$, iar W și b sunt parametrii stratului de clasificare antrenați prin fine-tuning.

3.4. TF-IDF ȘI LOGISTIC REGRESSION

O tehnică convențională de vectorizare a textului, bazată pe frecvența relativă a cuvintelor, se numește TF-IDF (Term Frequency Inverse Document Frequency) [6]. În timp ce IDF penalizează termenii care apar în mai multe lucrări, păstrând astfel termenii cu grad ridicat de discriminare, TF evaluează frecvența unui termen în cadrul unui document. Formal, scorul TF-IDF pentru termenul t în documentul d este definit ca:

$$TF\text{-}IDF(t, d) = TF(t, d) \times \log \frac{N}{df(t)} \quad (4)$$

unde $TF(t, d)$ este numărul de apariții ale termenului t în documentul d , N reprezintă numărul total de documente din corpus, $df(t)$ este numărul de documente care conțin termenul t .

Modelul de referință pentru această cercetare este un clasificator de regresie logistică care utilizează vectorii TF-IDF generați drept caracteristici. Regresia logistică estimează probabilitatea că un text este generat de AI printr-o funcție sigmoid aplicată combinației liniare a caracteristicilor:

$$\hat{y} = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}} \quad (5)$$

unde x este vectorul TF-IDF al textului, w sunt ponderile modelului, iar b este bias-ul.

3.5. METRICI DE EVALUARE

Pentru evaluarea modelelor de clasificare binară se utilizează următorii indicatori: precizia (Precision) reprezintă raportul dintre numărul de exemple pozitive clasificate corect și numărul total de exemple clasificate ca pozitive de către model, acuratețea (Accuracy) reprezintă procentul de predicții corecte din total, recall-ul (Recall) reprezintă raportul dintre numărul de exemple pozitive clasificate corect și numărul total de exemple pozitive reale, scorul F1 reprezintă media armonică a preciziei și a recall-ului, și matricea de confuzie (matricea erorilor de clasificare). Formal, acești indicatori sunt definiți pe baza elementelor matricei de confuzie, True Positive (TP), True Negative (TN), False Positive (FP) și False Negative (FN), astfel:

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (6)$$

$$Precision = \frac{TP}{TP+FP} \quad (7)$$

$$Recall = \frac{TP}{TP+FN} \quad (8)$$

$$F_1 = 2 \cdot \frac{Precision \times Recall}{Precision + Recall} \quad (9)$$

Utilizate împreună, aceste metrice oferă o imagine completă a performanței modelului, inclusiv a tipurilor specifice de erori comise.

4. SOLUȚIA PROPUȘĂ ȘI METODOLOGIA DE PROIECTARE/DEZVOLTARE

Obiectivul metodei de detectare prezentate în această lucrare este de a împărți automat textele în două categorii: textul generat de inteligența artificială și textul scris de oameni. Arhitectura generală a sistemului este alcătuită din trei componente principale: un modul de evaluare în scenarii multiple, un modul de antrenare bazat pe ajustarea modelului RoBERTa și un flux de preprocesare a datelor.

4.1. DESCRIEREA DATASET-ULUI HC3

Dataset-ul HC3 (Human ChatGPT Comparison Corpus), propus de Guo et al. (2023) [2] și accesibil publicului pe platforma HuggingFace [11], cuprinde 24.322 de întrebări distincte cu răspunsuri multiple: un răspuns generat de ChatGPT și, în cea mai mare parte, mai multe răspunsuri scrise de oameni (colectate din surse precum Reddit, Wikipedia și publicații medicale sau financiare).

Au fost colectate în total 84.391 de exemple după ce datele au fost restructurate într-un format de clasificare binară, în care fiecare răspuns individual servește drept exemplu de antrenare. Acestea sunt împărțite între 57.552 de texte scrise de oameni (etichetă 0) și 26.839 de texte create de ChatGPT (etichetă 1). Numărul mai mare de exemple din categoria răspunsurilor umane se explică prin faptul că, deși există un singur răspuns generat de ChatGPT pentru fiecare întrebare, există mai multe răspunsuri umane. În plus, lungimea medie a textelor generate de ChatGPT este de 1.013 cuvinte, în timp ce lungimea medie a textelor umane este de 692 de cuvinte. Acest lucru indică faptul că modelele de IA preferă să genereze răspunsuri mai complexe și mai structurate.

4.2. PREPROCESAREA ȘI ECHILIBRAREA DATELOR

Cu 57.552 de texte scrise de oameni (68%) și 26.839 de texte generate de ChatGPT (32%), dataset-ul inițial prezenta un dezechilibru notabil între clase (Figura 1). Atunci când un model de clasificare este antrenat pe date dezechilibrate, se introduce o tendință sistematică către clasa majoritară. Ca urmare, modelul tinde să prevadă majoritatea aparițiilor ca fiind text uman, atingând o precizie înșelător de mare fără a învăța cu adevărat să detecteze conținutul generat de IA.

Distributia claselor in dataset-ul HC3




Figura 1 – Distribuția claselor în dataset-ul HC3.

Un dataset complet echilibrat, cu un total de 53.678 de exemple (26.839 per clasă), a fost obținut prin aplicarea unei strategii de sub-eșantionare pentru a reduce numărul de exemple din clasa majoritară, astfel încât să se potrivească cu clasa minoritară (Figura 1). Numărul total de exemple din setul echilibrat este determinat de relația:

$$N_{echilibrat} = 2 \times \min(N_{uman}, N_{IA}) = 2 \times 26.839 = 53.678 \quad (10)$$

Folosind un parametru de stratificare pentru a menține distribuția precisă a claselor în toate diviziunile, dataset-ul echilibrat a fost apoi împărțit în trei subseturi separate: antrenare (80%), validare (10%) și testare (10%).

4.3. EXTINDEREA DATASET-ULUI CU TEXTE MULTI-MODEL

O limitare majoră a fost identificată în evaluările inițiale ale modelelor antrenate exclusiv pe textele ChatGPT din HC3, întrucât precizia cross-model a modelului RoBERTa v1 a fost de doar 25,96%, iar cea a modelului de referință de 17,30%. Din cauza acestei bariere de performanță, dataset-ul de antrenament a fost extins pentru a include texte generate de o gamă mai largă de modele de IA, utilizând API-ul Groq.

Ca urmare, cinci modele diferite au generat încă 4.932 de texte de IA (suplimentare față de textele ChatGPT deja existente în HC3), după cum se poate observa în Figura 2. Folosind o solicitare de sistem cu linii directe stricte de formatare pentru a elimina artefactele de markdown care ar putea adăuga zgomot procesului de antrenare, toate textele au fost create pe baza întrebărilor deja existente în HC3. În cele din urmă, modelul NVIDIA Nemotron (nemotron-3-super-120b-a12b) a fost complet eliminat din datele de antrenare și pus deoparte exclusiv pentru testare în cadrul evaluării robuste cross-model.




Figura 2 – Distribuția textelor generate per model de Inteligență Artificială.

4.4. CURĂȚAREA ȘI VERIFICAREA DATELOR

Fiecare fișier a fost examinat amănunțit și curățat înainte de combinarea seturilor de date. Textele generate de IA obținute prin API prezentau adesea artefacte de formatare, cum ar fi formatarea Markdown, fragmente expuse din lanțul de gândire — o caracteristică unică a unor modele care încorporează procesul lor intern de raționament în rezultatul final și caractere Unicode speciale (cum ar fi cratime neîntrerupte U+2011, ghilimele inteligente U+201C/U+201D și spații înguste neîntrerupte U+202F).

A fost implementat un pipeline de curățare a datelor pentru a executa substituții de caractere Unicode, a elimina marcajul Markdown folosind expresii regulate și a filtra textele cu mai puțin de 80 de caractere, pentru a aborda metodic aceste probleme. În plus, a fost necesară o etapă suplimentară de procesare pentru a exclude cinci fragmente recunoscute de lanț de gândire din textele produse de modelul Nemotron, rezultând 139 de texte curate pentru evaluarea cross-model.

4.5. CONSTRUIREA DATASET-ULUI FINAL ȘI ÎMPĂRȚIREA ÎN SUBSETURI

Textele din HC3 au fost combinate cu textele generate prin API pentru a crea dataset-ul final utilizat la antrenarea modelului RoBERTa v2. Pentru a menține echilibrul perfect al claselor după adăugarea celor 4.932 de texte IA generate prin API, un număr echivalent de texte umane suplimentare a fost extras din rezerva rămasă în dataset-ul original HC3, ajungându-se astfel la un total de 31.771 de exemple pentru fiecare clasă.

Împărțirea în subansambluri s-a realizat la nivel de întrebare, și nu la nivel de text individual, pentru a preveni contaminarea datelor. Dacă aceeași întrebare apărea atât în setul de antrenare, cât și în cel de testare (chiar și cu răspunsuri diferite), modelul ar fi putut învăța în mod neintenționat să identifice anumite subiecte, în loc să diferențieze stilul real de scriere al IA.

Pentru a asigura că nu există suprapuneri între subgrupuri, 80% din cele 23.492 de întrebări unice au fost alocate antrenării, 10% validării și 10% testării. Această valoare este mai mică decât numărul total de 24.322 de întrebări din setul brut HC3, deoarece procesul de curățare (secțiunea 4.4) a eliminat răspunsurile mai scurte de 50 de caractere. Întrebările pentru care nu mai existau răspunsuri valide în ambele clase au fost excluse, rezultând astfel 23.492 de întrebări utilizabile.

Tabelul 1 prezintă distribuția finală obținută după sub-eșantionare pentru a echilibra clasele. Deoarece împărțirea s-a realizat la nivel de întrebare, numărul efectiv de exemple per subset diferă ușor de o proporție exactă 80/10/10 aplicată la nivel de text.

Tabelul 1. Distribuția dataset-ului final după echilibrare

Subset	Total Exemple	Texte umane	Texte AI
Antrenare	50.626	25.313	25.313
Validare	6.400	3.200	3.200
Testare	6.516	3.258	3.258
Total	63.542	31.771	31.771

5. IMPLEMENTARE

Mediul de dezvoltare, arhitectura modelelor implementate și detaliile tehnice ale procedurii de antrenare sunt prezentate în acest capitol, care tratează implementarea tehnică a sistemului de detectare a textului generat de IA.

5.1. MEDIUL DE DEZVOLTARE ȘI TEHNOLOGII UTILIZATE

Folosind o colecție de module specializate de învățare automată și de procesare a limbajului natural, sistemul de detectare a fost implementat în Python 3. Modelele Transformer preantrenate au fost gestionate cu ajutorul bibliotecii HuggingFace Transformers [17], care a oferit utilizatorilor acces la arhitectura RoBERTa și la tokenizer. Cadrul de învățare profundă utilizat pentru definirea și antrenarea modelelor a fost PyTorch [18]. Modelul de referință TF-IDF + Regresie logistică a fost implementat, iar indicatorii de evaluare au fost calculați folosind setul de instrumente scikit-learn [19].

Graphics Processing Unit (GPU) NVIDIA T4, disponibil gratuit în cadrul planului standard, a fost utilizat pentru antrenarea modelului RoBERTa pe platforma Google Colab. Această decizie a permis antrenarea pe seturi de date cu zeci de mii de eșantioane, fără a genera costuri de infrastructură. Cu o dimensiune a lotului de 16 și o lungime maximă de 128 de tokenuri, durata de antrenare pe setul de antrenament de 50.626 de eșantioane a fost de aproximativ 50 de minute pe epocă.

API-ul OpenRouter pentru modelul NVIDIA Nemotron, care a fost păstrat pentru testarea cross-model, și API-ul Groq pentru o gamă de modele lingvistice au fost utilizate pentru a genera texte AI pentru extinderea setului de date. Integrarea în programarea Python este facilitată de interfața compatibilă cu OpenAI a ambelor API-uri.

5.2. IMPLEMENTAREA MODELULUI BASELINE — TF-IDF + LOGISTIC REGRESSION

Modelul de referință (baseline) a fost implementat folosind clasa TfidfVectorizer din scikit-learn [19], configurată cu parametrii: max_features=50.000 (vocabular limitat la cei mai frecvenți 50.000 termeni), ngram_range=(1,2) (unigrami și bigrami), min_df=2 (ignorarea termenilor cu frecvență sub 2 apariții) și lowercase=True. Bigramele permit capturarea unor pattern-uri lexicale de două cuvinte caracteristice textului AI, îmbunătățind performanța față de unigrami simpli.

Clasificatorul Logistic Regression a fost configurat cu max_iter=1000 (număr maxim de iterații pentru convergență), C=1.0 (parametrul de regularizare implicit) și random_state=42 (pentru reproducibilitate). Pipeline-ul complet, vectorizare TF-IDF urmată de clasificare a fost antrenat pe cele 42.947 de exemple din setul de antrenare v1 și evaluat pe setul de test de 5.368 de exemple (2.684 texte umane și 2.684 texte ChatGPT).

5.3. IMPLEMENTAREA FINE-TUNING ROBERTA

Prima iterație a modelului, RoBERTa v1, a fost antrenată exclusiv pe datele HC3, utilizând setul de antrenare v1 compus din 42.947 de exemple echilibrate (21.473 texte umane și 21.474 texte ChatGPT). Evaluarea a fost realizată pe setul de test v1 de 5.368 de exemple.

Folosind clasa RobertaForSequenceClassification din HuggingFace Transformers [17] și opțiunea num_labels=2, arhitectura RoBERTa-base a fost adaptată pentru clasificarea binară. Modelul pre-antrenat a fost descărcat automat din repository-ul oficial HuggingFace și are 125 de milioane de parametri.

RobertaTokenizer a fost utilizat pentru tokenizarea textului cu următoarele setări: max_length=128 tokenuri, padding="max_length" (completare până la lungimea maximă) și truncation=True (truncare până la lungimea maximă). Lungimea de 128 de tokenuri a fost selectată ca un compromis între eficiența computațională și acoperirea materialului relevant; o examinare a distribuției lungimii textului din dataset-ul a relevat că 85% din texte se încadrează în acest interval.

Pentru antrenare s-a utilizat optimizatorul AdamW, cu o decădere a ponderilor de 0,01 pentru regularizare și o rată de învățare de 2e-5. 10% din pașii de antrenare au fost dedicați creșterii progresive a ratei de învățare folosind un program de încălzire liniar, o metodă obișnuită pentru fine-tuningul modelelor de tip transformer, care evită modificările excesive ale parametrilor în primele iterații.

Se utilizează entropia încrucișată binară (Binary Cross-Entropy loss), o funcție de pierdere obișnuită pentru clasificarea binară. Pentru clasificarea binară, aceasta este definită ca:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)] \quad (11)$$

unde N este numărul de exemple din lot, $y_i \in \{0,1\}$ este eticheta reală, iar $\hat{y}_i$ este probabilitatea prezisă de model pentru clasa pozitivă (text AI).

Gradienții au fost limitați la o normă maximă de 1,0 prin gradient clipping, prevenind astfel explozia gradientilor. După două epoci de antrenare, modelul a fost oprit, deoarece acuratețea de validare a atins 99,93%.

Folosind aceiași hiperparametri - o rată de învățare de 2e-5, o dimensiune a lotului de 16, o lungime maximă de 128 de tokenuri și optimizatorul AdamW cu o decădere a ponderilor de 0,01 - a doua iterație a modelului, RoBERTa v2, a fost antrenată pe dataset-ul multimodel extins (50.626 de eșantioane). Spre deosebire de RoBERTa v1, antrenarea

s-a finalizat pe parcursul celor trei epoci programate, iar metoda de checkpointing a stocat automat modelul care a avut cea mai bună performanță pe setul de validare.




Figura 3 – Funcția de pierdere și acuratețea RoBERTa v2.

În cadrul implementării a fost integrat un mecanism de păstrare a celui mai bun model; la finalul fiecărei epoci, modelul era salvat dacă acuratețea de validare depășea cel mai bun rezultat anterior. Această metodă garantează că modelul ales în final pentru evaluare nu este cel din epoca anterioară, ci cel care prezintă cea mai bună performanță pe setul de validare.

5.4. PIPELINE-UL DE GENERARE A TEXTELOR MULTI-MODEL

Pentru generarea de texte în vederea extinderii setului de date s-a utilizat un flux automatizat compus din trei componente principale: selectarea întrebărilor din HC3, apelarea API-urilor de generare și curățarea textului.

Pentru reproductibilitate, în procesul de selecție a întrebărilor s-a utilizat eșantionarea aleatorie cu `random_state=123`. Pentru a se asigura că textele rezultate erau comparabile, fiecărui model i s-a dat setul identic de 1.000 de întrebări. În schimb, pentru modelul NVIDIA Nemotron (rezervat exclusiv evaluării cross-model), din considerente legate de limitele de generare, s-a generat un set redus de texte, care au fost ulterior curățate de artefacte. Pentru a preveni artefactele de formatare care ar fi putut adăuga zgomot la antrenare, instrucțiunea de sistem (prompt) conținea linii directe stricte de formatare: text simplu fără markdown, fără liste, fără titluri și un răspuns în două până la patru fraze.

Procesul de curățare a prelucrat textele generate prin normalizarea spațiilor multiple, eliminarea formătărilor Markdown folosind expresii regulate și înlocuirea caracterelor speciale Unicode (U+2011 - cratimă neîntreruptă, U+201C/U+201D - ghilimele tipografice și U+202F - spațiu îngust neîntrerupt) cu echivalentele lor ASCII. După curățare, textele cu mai puțin de 80 de caractere au fost eliminate.

5.5. SALVAREA ȘI UTILIZAREA MODELULUI

Modelul RoBERTa v2 finalizat a fost stocat în formatul standard HuggingFace și includea următoarele fișiere: `tokenizer.json`, `tokenizer_config.json`, `model.safetensors` (ponderile modelului, ~500 MB) și `config.json` (configurația arhitecturii). Cu ajutorul funcțiilor `from_pretrained()` din biblioteca HuggingFace Transformers, acest format permite reîncărcarea și utilizarea modelului fără a fi necesară reantrenarea.

Tokenizarea textului de intrare, rularea inferenței cu modelul (forward pass fără calculul gradientului, sub `torch.no_grad()`), aplicarea funcției softmax la logits pentru a obține probabilitățile clasei și utilizarea argmax pentru a determina clasa precisă constituie fluxul de lucru pentru inferența asupra textelor noi. Scorul de încredere a detectorului este reprezentat de probabilitatea clasei prezise.

6. REZULTATE EXPERIMENTALE

6.1. REZULTATE BASELINE (TF-IDF + LOGISTIC REGRESSION)

Pe setul de testare din același domeniu (texte ChatGPT), modelul de referință TF-IDF + Logistic Regression a obținut o acuratețe de 97,32%. Modelul a identificat incorect 144 dintre cele 5.368 de cazuri de testare, clasificând 67 de texte scrise de oameni ca fiind generate de IA și 77 de texte generate de IA ca fiind scrise de oameni. Pentru ambele clase, valorile preciziei, ale recall-ului și ale scorului F1 au fost de 0,97 (Figura 4).




Figura 4 – Matricea de confuzie TF-IDF + Logistic Regression.

Rezultatele lucrării actuale arată că aceste metode pot produce performanțe remarcabil de bune în situația in-domain prin vectorizarea textelor în spațiul token și antrenarea unui clasificator liniar (acuratețe de 97.32%). Principalul dezavantaj al abordărilor lexicale este sensibilitatea lor la distribuția specifică a vocabularului modelului de IA de antrenare, ceea ce provoacă o degradare semnificativă în situațiile cross-model.

O acuratețe de doar 17,30% a fost constatată într-o evaluare Cross-Model a 497 de texte produse de gpt-oss-20b, identificând corect 86 dintre cele 497 de texte generate de IA. Această scădere bruscă arată că modelele bazate pe caracteristici lexicale se adaptează excesiv la stilul particular de antrenare al modelului de IA.

6.2. REZULTATE ROBERTA V1 (ANTRENAT EXCLUSIV PE CHATGPT)

Pe setul de testare din cadrul aceluiași domeniu, modelul RoBERTa v1, antrenat exclusiv pe texte ChatGPT din HC3, a atins o acuratețe de 99,91%. Doar cinci dintre cele 5.368 de exemple, două texte generate de IA etichetate ca fiind scrise de oameni și trei texte scrise de oameni clasificate ca fiind generate de IA, au fost clasificate incorect de model (Figura 5). Acuratețea a scăzut la 25,96% în scenariul cross-model pe textele gpt-oss-20b, demonstrând că și arhitecturile transformer antrenate pe o singură sursă suferă de o degradare severă a capacității de generalizare.




Figura 5 – Matricea de confuzie – RoBERTa.

Figura 6 ilustrează sensibilitatea modelului RoBERTa v1 la textele din afara distribuției. După cum se poate observa, precizia scade substanțial atunci când aceleași ponderi ale rețelei neuronale sunt evaluate pe generațiile modelului gpt-oss-20b, chiar dacă

performanța în cazul textelor in-domain (ChatGPT) atinge un nivel de detectare aproape perfect.




Figura 6 – Comparație Acuratețe: ChatGPT vs gpt-oss-20b.

Ideea principală a acestui articol, și anume că modelele de detectare antrenate pe un singur generator de IA sunt extrem de predispuse la suprapotrivire (overfitting) în raport cu stilul lingvistic specific al aceluși model, este susținută de această discrepantă enormă (o scădere de aproximativ 74 de puncte procentuale). Prin urmare, reantrenarea modelului pe un dataset care include mai multe modele este necesară, deoarece o astfel de metodă monolitică este insuficientă pentru crearea unui detector fiabil în situații reale.

6.3. REZULTATE ROBERTA V2 (ANTRENAT PE DATASET MULTI-MODEL)

Modelul RoBERTa v2 a atins o acuratețe de 99,62% pe setul de testare in-domain după ce a fost antrenat pe dataset-ul extins care a inclus texte de la cinci modele AI diferite. O acuratețe de 88,49% a fost constatată prin evaluarea cross-model pe un set de 139 de texte produse de NVIDIA Nemotron (evaluate în raport cu 139 de texte umane din HC3), ceea ce reprezintă o îmbunătățire de +62,53 puncte procentuale față de RoBERTa v1 (25,96%). Această îmbunătățire semnificativă susține teoria conform căreia generalizarea cross-model este determinată de diversitatea surselor de antrenare.




Figura 7 – Matricea de confuzie pentru modelul RoBERTa v2 în evaluarea cross-model (NVIDIA Nemotron vs. Uman).

Modelul RoBERTa v2 a clasificat corect 138 dintre cele 139 de texte umane, generând un singur fals pozitiv, ceea ce a dus la o precizie de 99,28% pentru clasa „uman”. În schimb, 31 dintre textele generate de Nemotron au fost clasificate eronat ca fiind scrise de oameni (fals negativ), rezultând un scor F1 de 87,10% pentru clasa „IA”. Această distribuție reflectă o tendință dezirabilă pentru un sistem de detecție: se acordă prioritate reducerii alarmelor false (clasificarea greșită a textelor umane ca fiind AI) în detrimentul unei rate ușor mai scăzute de detectare a textelor generate de IA.




Figura 8 – Distribuția scorurilor de probabilitate (încredere) generate de RoBERTa v2.

Având probabilități polarizate în mod substanțial către valorile extreme 0 și 1, modelul demonstrează un nivel ridicat de încredere în deciziile sale, așa cum se poate observa în Figura 8. Statistica ROC-AUC, care atinge o valoare de 0,9841, confirmă și mai mult calitatea bună a clasificării, care este independentă de un prag fix. Această performanță susține ideea că diversitatea surselor de antrenare determină în mod strict generalizarea cross-model.

6.4. VALIDARE EXTERNĂ PE RAID BENCHMARK

Dataset-ul RAID Benchmark [3], elaborat de cercetătorii de la Universitatea din Washington și care include texte generate de mai multe modele de IA, precum și texte scrise de oameni din diverse domenii de activitate, a fost utilizat pentru evaluarea modelului RoBERTa v2 în scopul validării externe a acestuia. Pentru fiecare dintre cele 11 modele AI au fost evaluate câte 500 de texte generate împreună cu 500 de texte scrise de oameni, selectate dintr-o varietate de domenii (știri, articole Wikipedia, eseuri etc). Modelul RoBERTa v2 nu a fost antrenat pe niciun text din RAID. Menționăm însă că, dintre cele 11 modele generative evaluate, ChatGPT este singurul model in-domain (fiind sursa textelor AI din setul HC3 folosit la antrenare), motiv pentru care rezultatele acestuia sunt raportate separat de media cross-model calculată pe celelalte 10 modele. Rezultatele prezentate în Figura 9 au fost obținute în urma evaluării a 11 modele de IA diferite.




Figura 9 – Acuratețea RoBERTa v2 pe RAID Benchmark.

Acuratețea variază semnificativ în funcție de tipul modelului generativ evaluat, conform unui studiu comparativ al rezultatelor prezentate în Figura 9. În timp ce modelele de bază (precum mistral, mpt și gpt2) înregistrează o acuratețe mai scăzută (între 61,30% și 86,40%), modelele din categoria „chat/instruct” prezintă performanțe superioare, atingând o acuratețe medie extrem de ridicată (ex: 99,00% pentru llama-chat și 98,70% pentru gpt3). Această diferență majoră este determinată de compoziția setului de antrenament al detectorului RoBERTa v2, care a fost creat exclusiv pe baza textelor generate de modele perfecționate conversațional. O posibilă explicație pentru acuratețea mai scăzută pe modelele de bază este aceea că acestea nu au trecut printr-un proces de aliniere conversațională (RLHF), ceea ce le face să genereze texte cu o structură diferită față de modelele fine-tuned incluse în antrenament. Totuși, această ipoteză necesită investigații suplimentare.

În setul de antrenare al detectorului au fost incluse doar textele generate de modelele fine-tuned, ChatGPT (din HC3), Llama 3.3, Llama 4 Scout, Llama 3.1, și variantele gpt-oss. În antrenarea v2 au fost incluse atât gpt-oss-20b, cât și gpt-oss-120b, deși gpt-oss-20b fusese utilizat anterior ca model cross-model pentru evaluarea v1 (secțiunile 6.1–6.2). Ca urmare, procesul de fine-tuning a optimizat clasificatorul pentru a identifica anumite tipare stilistice și structurale specifice acestor modele fine-tuned, precum utilizarea frazelor de tranziție repetitive tipice procesului de aliniere prin feedback uman (RLHF – Reinforcement Learning from Human Feedback), organizarea ierarhică a informațiilor și prezența formulărilor standardizate la începutul răspunsurilor.

Tiparele lingvistice pe care clasificatorul le învață sunt mult mai puțin frecvente atunci când detectorul este utilizat împreună cu modele de bază precum Mistral (61,30%)

sau MPT (62,00%), care generează text brut fără aceste constrângeri conversaționale. Ratele mai ridicate de fals negative (clasificarea eronată a textelor generate de IA ca fiind scrise de oameni) se reflectă în scoruri de încredere mai mici ale clasificatorului, datorate diversității lexicale sporite și lipsei unei structuri fixe de răspuns.

În plus, deși atât GPT-3, cât și GPT-4 sunt modele fine-tuned, performanța pe GPT-4 (96,10%) este puțin mai slabă decât cea pe GPT-3 (98,70%). Detectorul a fost antrenat să recunoască tipare rigide specifice generațiilor mai vechi, dar această discrepanță de 2,60 puncte procentuale indică faptul că generațiile mai recente, mai sofisticate din punct de vedere lingvistic, se abat oarecum de la aceste tipare. În final, distribuția scorurilor din Figura 9 confirmă faptul că eficacitatea detectorului este strâns corelată cu nivelul de similitudine stilistică dintre modelul testat și modelele din setul de antrenament.

Pentru o perspectivă analitică mai profundă, dincolo de acuratețea globală, Tabelul 2 prezintă metricile de performanță detaliate (Precizie, Sensibilitate/Recall și scorul F1) pentru fiecare model evaluat, alături de numărul exact de instanțe clasificate corect (TP, TN) și eronat (FP, FN)

Tabelul 2. Valori RAID Benchmark

Model	Accuracy	Precision	Recall	F1	TP	FN	FP	TN
Chatgpt	99.20%	98.62%	99.80%	99.20%	499	1	7	493
Llama-chat	99.00%	98.61%	99.40%	99.00%	497	3	7	493
Gpt3	98.70%	98.60%	98.80%	98.70%	494	6	7	493
Mistral-chat	96.90%	98.55%	95.20%	96.85%	476	24	7	493
Cohere-chat	96.80%	98.55%	95.00%	96.74%	475	25	7	493
Gpt4	96.10%	98.53%	93.60%	96.00%	468	32	7	493
Mpt-chat	93.70%	98.45%	88.80%	93.38%	444	56	7	493
Cohere	90.00%	98.31%	81.40%	89.06%	407	93	7	493
Gpt2	86.40%	98.15%	74.20%	84.51%	371	129	7	493
Mpt	62.00%	94.78%	25.40%	40.06%	127	373	7	493
Mistral	61.30%	94.49%	24.40%	38.28%	120	380	7	493

Analiza datelor din tabel arată o rată foarte scăzută a alarmelor false, numărul de rezultate fals pozitive rămânând la 7 din 500 de mesaje scrise de oameni, ceea ce corespunde unei rate de specificitate de 98,6%. Așa cum se întâmplă de obicei în cazul modelelor de bază, rata rezultatelor fals negative (texte generate de IA nedetectate) continuă să fie principala cauză a erorilor de precizie, ceea ce indică faptul că modelul RoBERTa v2 este conservator în ceea ce privește penalizarea cuvintelor scrise de oameni.

6.5. COMPARAȚIE FINALĂ

Modelul de referință a fost evaluat și folosind setul de testare v2 (6.516 eșantioane provenite de la 6 modele AI diferite), care a fost utilizat și pentru evaluarea RoBERTa v2, în scopul de a asigura o comparație echitabilă. Acuratețea pe acest set a fost de 93,17% pentru modelul de referință TF-IDF + Regresie logistică și de 99,62% pentru RoBERTa v2, o diferență de +6,45 puncte procentuale. Chiar și în scenariul in-domain, modelele bazate pe caracteristici lexicale sunt parțial sensibile la diversitatea modelelor de IA, după cum o demonstrează scăderea față de evaluarea din cadrul domeniului pe v1 (97,32% → 93,17%). Modelul de referință clasifică eronat mai multe texte umane ca fiind generate de IA atunci când textele generate de IA provin de la modele diferite, după cum o demonstrează precizia scăzută pentru clasa umană (0,90).




Figura 10 – Matricea de confuzie – Baseline pe test V2

Analiza matricei de confuzie a modelului de referință (Figura 10) ilustrează pe larg modul în care tehnicile statistice tradiționale nu reușesc să generalizeze corespunzător într-un peisaj de generare diversificat. O comparație consolidată a performanțelor finale între modelul de referință și arhitectura avansată RoBERTa în toate cele trei scenarii principale

de evaluare, in-domain v1, in-domain v2 și cross-model RAID, este prezentată în Tabelul 3 pentru a oferi o imagine de ansamblu asupra traiectoriei generale a experimentului.

Tabelul 3. Comparație finală — toate scenariile de evaluare

Model	In-domain	Cross-model
Baseline TF-IDF + LR (setul v1)	97.32%	17.30%
Baseline TF-IDF + LR (setul v2)	93.17%	-
RoBERTa v1 (ChatGPT only)	99.91%	25.96%
RoBERTa v2 (Multi-model)	99.62%	88.49%
RoBERTa v2 (RAID)	-	88.09%

Modelul RoBERTa v2 atinge o acuratețe „in-domain” de 99,62% în comparație cu lucrarea lui Wang et al. (2023) [9], care a atins o acuratețe de 98% pe un dataset similar. În plus, spre deosebire de metoda lor, în prezenta lucrare s-a obținut o medie de 88,09% atunci când am validat în detaliu capacitatea de generalizare între modele pe benchmark-ul RAID.

7. CONCLUZII, CONTRIBUȚII ȘI DIRECȚII DE CONTINUARE A DEZVOLTĂRII

7.1. CONCLUZII

Lucrarea de față a investigat problema detecției automate a textului generat de inteligența artificială prin două abordări complementare: un model de referință (baseline) bazat pe TF-IDF și Logistic Regression și un model avansat bazat pe fine-tuning al arhitecturii RoBERTa.

Rezultatele demonstrează că detecția textului AI este fezabilă cu acuratețe ridicată în scenariul in-domain: modelul baseline a atins 97,32%, iar RoBERTa v1 a obținut 99,91%. Evaluarea cross-model a revelat o limitare critică a abordării cu o singură sursă de antrenare: ambele modele au prezentat o degradare severă (17,30% și respectiv 25,96%) pe texte generate de modele AI diferite față de cel din antrenare.

Diversificarea dataset-ului de antrenare cu texte din 5 modele AI diverse a condus la o îmbunătățire dramatică a capacității de generalizare cross-model: RoBERTa v2 a obținut 88,49% pe NVIDIA Nemotron și 88,09% medie cross-model pe celelalte 10 modele din RAID Benchmark (excluzând ChatGPT, singurul model in-domain dintre cele 11 evaluate). Aceste rezultate confirmă că diversitatea surselor de antrenare este factorul determinant pentru generalizarea detectorului.

7.2. CONTRIBUȚIILE ORIGINALE ALE LUCRĂRII

Contribuțiile originale ale prezentei lucrări sunt:

- (1) Evaluarea comparativă sistematică a două abordări de detecție — statistică clasică și transformer — în scenarii multiple de evaluare;
- (2) Generarea unui dataset original de 4.932 texte AI din 5 modele diverse, folosind API-ul Groq, cu instrucțiuni stricte de formatare pentru calitate maximă;
- (3) Demonstrarea experimentală că diversificarea surselor de antrenare îmbunătățește acuratețea cross-model de la 25,96% la 88,49% (+62,53 puncte procentuale);
- (4) Validarea externă pe RAID Benchmark, care include modele parțial similare și parțial diferite față de cele din antrenament, a confirmat o bună capacitate de generalizare.

7.3. LIMITĂRI

Lucrarea prezintă câteva limitări care trebuie menționate explicit. În primul rând, mărimea eșantionului a fost limitată la 139 de texte din cauza limitelor de rată ale interogărilor (rate limits) ale API-ului utilizat pentru extragerea textelor pentru NVIDIA Nemotron. Acest lucru limitează capacitatea de a determina semnificația statistică pentru acest model specific. În al doilea rând, un studiu Stanford (2023) [8] a arătat că detectoarele

de text AI prezintă un bias față de vorbitorii non-nativi de engleză, cu rate de fals pozitive care pot depăși 60% pentru anumite grupuri, iar aproape 20% dintre eseuri fiind clasificate în unanimitate ca generate de IA, o limitare care afectează și sistemul prezent, antrenat exclusiv pe texte în engleză.

7.4. DIRECȚII VIITOARE DE CERCETARE

Direcțiile principale de continuare a dezvoltării includ:

- (1) Extinderea dataset-ului de antrenare cu texte din domenii diverse (știri, recenzii, eseuri) pentru îmbunătățirea generalizării pe domenii;
- (2) Implementarea tehnicilor de adaptare la domeniu (domain adaptation) pentru reducerea bias-ului față de vorbitorii non-nativi;
- (3) Evaluarea robusteții față de atacuri adversariale — text parafrizat, inserare de caractere Unicode sau modificări stilistice deliberate;
- (4) Extinderea detecției la nivel de paragraf sau frază, nu doar la nivel de document, pentru identificarea textului AI parțial în lucrări mixte.

8. BIBLIOGRAFIE

- [1] Y. Liu et al., "RoBERTa: A Robustly Optimized BERT Pretraining Approach," arXiv:1907.11692, 2019. [Online]. Available: <https://arxiv.org/abs/1907.11692>
- [2] B. Guo et al., "How Close is ChatGPT to Human Experts? Feedback from Evaluation of Responses using the HC3 Dataset," arXiv:2301.07597, 2023. [Online]. Available: <https://arxiv.org/abs/2301.07597>
- [3] L. Dugan et al., "RAID: A Shared Benchmark for Robust Evaluation of Machine-Generated Text Detectors," arXiv:2405.07940, 2024. [Online]. Available: <https://arxiv.org/abs/2405.07940>
- [4] A. Vaswani et al., "Attention Is All You Need," arXiv:1706.03762, 2017. [Online]. Available: <https://arxiv.org/abs/1706.03762>
- [5] J. Devlin et al., "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," arXiv:1810.04805, 2019. [Online]. Available: <https://arxiv.org/abs/1810.04805>
- [6] J. Ramos, "Using TF-IDF to Determine Word Relevance in Document Queries," in *Proc. First Instructional Conference on Machine Learning*, 2003.
- [7] E. Mitchell et al., "DetectGPT: Zero-Shot Machine-Generated Text Detection using Probability Curvature," arXiv:2301.11305, 2023. [Online]. Available: <https://arxiv.org/abs/2301.11305>
- [8] W. Liang et al., "GPT Detectors Are Biased Against Non-Native English Writers," arXiv:2304.02819, 2023. [Online]. Available: <https://arxiv.org/abs/2304.02819>
- [9] Z. Wang et al., "Implementing BERT and fine-tuned RoBERTa to detect AI generated news by ChatGPT," arXiv:2306.07401, 2023. [Online]. Available: <https://arxiv.org/abs/2306.07401>
- [10] I. Solaiman et al., "Release Strategies and the Social Impacts of Language Models," arXiv:1908.09203, 2019. [Online]. Available: <https://arxiv.org/abs/1908.09203>
- [11] Hello-SimpleAI, "HC3 Dataset," Hugging Face, 2023. [Online]. Available: <https://huggingface.co/datasets/Hello-SimpleAI/HC3> [Accessed: May 2026].
- [12] RAID Benchmark, "RAID Dataset," Hugging Face, 2024. [Online]. Available: <https://huggingface.co/datasets/liamdugan/raid> [Accessed: May 2026].

[13] A. Uchendu et al., "TuringBench: A Benchmark Environment for Turing Test in the Age of Neural Text Generation," arXiv:2109.13296, 2021. [Online]. Available: <https://arxiv.org/abs/2109.13296>

[14] GPTZero, "AI Content Detector," 2026. [Online]. Available: <https://gptzero.me> [Accessed: May 2026].

[15] Turnitin, "AI Writing Detection," 2026. [Online]. Available: <https://www.turnitin.com/products/features/ai-writing-detection> [Accessed: May 2026].

[16] H. Desaire et al., "Distinguishing Academic Science Writing from ChatGPT-Generated Text Using an AI Classifier," *Cell Reports Physical Science*, vol. 4, no. 6, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S266638642300200X>

[17] T. Wolf et al., "Transformers: State-of-the-Art Natural Language Processing," arXiv:1910.03771, 2020. [Online]. Available: <https://arxiv.org/abs/1910.03771>

[18] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," arXiv:1912.01703, 2019. [Online]. Available: <https://arxiv.org/abs/1912.01703>

[19] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011. [Online]. Available: <https://jmlr.org/papers/v12/pedregosa11a.html>

[20] University of Oxford, "AI use in summative assessment," Governance and Planning, Jul. 2025. [Online]. Available: <https://governance.admin.ox.ac.uk/education-committee/policies/ai-use-in-summative-assessment> [Accessed: May 2026].

[21] A. Schmalz and A. Tack, "Can GPTZero's AI Vocabulary Distinguish Between LLM-Generated and Student-Written Essays?" in Proc. BEA Workshop, 2025. [Online]. Available: <https://aclanthology.org/2025.bea-1.71>

DECLARAȚIE DE AUTENTICITATE A LUCRĂRII DE FINALIZARE A STUDIILOR